

R10 — Análisis de sensibilidad y robustez: detectabilidad del diseño, permutación, supuestos y bootstrap del efecto

Informe de resultados. Pipeline productor: PsyConn 7 sobre las 13 métricas del pool 6.1.1 (8 globales + 4 nodales no redundantes + degree_entropy), ds006072. Estado de los archivos: 7.1 y 7.2 re-ejecutados 2026-05-25 12:46 con el contrato r2 (pool_13_long + get_paired_vectors unificados en el chunk 7.0; n_max_exact = 16L para enumerar el espacio completo 2^N con $N=6$; GLOBAL_SEED = 2025L; renombrado de cohen_d $\rightarrow$ d_z en la curva de potencia para alinear con pwr.t.test(paired) que toma d_z como entrada). 7.3 y 7.4 ejecutados 2026-05-25 01:11-01:12 con la misma versión de pipeline; los valores que consumen (d_z, shapiro_p, Δ_i pareados) son idénticos a los que produciría una re-ejecución actual porque la cascada STATS_13_1 r3 de las 10:55 no toca esas columnas para el pool 13 (los cambios r3 —z-score LOO, na.rm = TRUE— sólo afectan a 6.1.3 y al subset nodal con NAs en participation, que ya están sin NA aquí). Fecha de la última re-ejecución de los archivos consumidos: 2026-05-25 10:55 (STATS_13_1 r3), 12:46 (7.1, 7.2), 01:12 (7.3, 7.4). $N = 6$ sujetos comunes (sub-P1, P3, P4, P5, P6, P7), idénticos a R3–R9.

Hallazgos

7 cierra la inferencia confirmatoria del pool topológico 6.1.1 con un cuádruple chequeo de robustez sobre los mismos $N = 6$ sujetos pareados que sostienen R3 a R9: detectabilidad a priori del diseño, triangulación paramétrica vs permutacional, verificación visual y heredada del supuesto de normalidad, e IC del tamaño del efecto sin asumir distribución asintótica. La lectura del cuadro completo es coherente con lo que R3 dejó establecido —ninguna métrica sobrevive FDR, pero el patrón direccional del cerebro entrópico es estable—, añade una pieza nueva (el diseño está infrapotenciado para detectar al 80 % los d_z observados, aunque por muy poco en varias métricas) y deja todos los caveats donde corresponden, no en una sección anexa sino en la interpretación misma de cada bloque.

El diseño detecta al 80 % efectos $|d_z| \geq 1.41$, no menos — y siete de las trece métricas caen casi sobre la línea

7.1 se hace una pregunta a priori sobre el diseño, no sobre los datos. Con $N = 6$ pareados y $\alpha = 0.05$ bilateral, ¿qué tamaño de efecto puede esperar detectar este crossover al 80 % de potencia? `pwr.t.test(type = "paired")` devuelve $d_{\min,80} = 1.41$ — efectos por debajo de ese umbral pueden ser reales pero quedan por debajo del piso de detectabilidad del diseño con esta N . La curva es una propiedad del diseño, no de los datos observados, y eso la distingue tajantemente de la potencia post-hoc, que Hoenig y Heisey [1] demuestran ser una función uno a uno del p-valor observado y por tanto matemáticamente inútil como diagnóstico; Lenth [2] lo expresa de forma aún más directa: «*observed power is a one-to-one function of the p-value*». La curva de sensibilidad evita ese error porque toma el efecto como parámetro, no como observación.

Al cruzar la curva con los $|d_z|$ observados en el pool 13 (la columna detectable del CSV es directamente el booleano $|d_z| \geq d_{\min,80}$), el resultado es uniforme y reseñable: **ninguna de las 13 métricas cae por encima del umbral**. Doce métricas se quedan dentro de la franja infradetectable ($|d_z| < 1.41$) y una sola —eigenvector con $|d_z| = 1.26$ — se acerca lo bastante para que un n requerido modesto (8 sujetos pareados al 80 %) baste para confirmarla en un estudio sucesor.

Si se ordena el pool por la magnitud del efecto y se anota el n requerido para alcanzar 80 % de potencia con ese efecto exacto, queda visible cuántas métricas están *casi* en zona detectable y cuántas están francamente lejos:

Plano	Métrica	d_z	$\ d_z\ $	p_{FDR}	Detectable	n requerido	Interpretación 7.1
nodal	eigenvector	+1.261	1.261	0.117	FALSE	8	No significativo + infradetectable (no descarta efecto real)
nodal	participation	-1.111	1.111	0.117	FALSE	9	No significativo + infradetectable (no descarta efecto real)
nodal	betweenness	1.065	1.065	0.117	FALSE	10	No significativo + infradetectable (no descarta efecto real)
global	assortativity	-1.058	1.058	0.117	FALSE	10	No significativo + infradetectable (no descarta efecto real)

Plano	Métrica	d_z	$\ d_z\ $	p_{FDR}	Detectable	n requerido	Interpretación 7.1
global	char_path_length	+0.985	1.035	0.117	FALSE	10	No significativo + infradetectable (no descarta efecto real)
global	clustering	+0.972	0.972	0.117	FALSE	11	No significativo + infradetectable (no descarta efecto real)
global	mean_strength	+0.971	0.971	0.117	FALSE	11	No significativo + infradetectable (no descarta efecto real)
global	global_efficiency	+0.890	0.890	0.132	FALSE	12	No significativo + infradetectable (no descarta efecto real)
global	density	+0.783	0.783	0.164	FALSE	15	No significativo + infradetectable (no descarta efecto real)
global	small_worldness	+0.662	0.662	0.215	FALSE	20	No significativo + infradetectable (no descarta efecto real)
global	modularity	-0.623	0.623	0.222	FALSE	23	No significativo + infradetectable (no descarta efecto real)
advanced	degree_entropy	+0.199	0.199	0.701	FALSE	201	No significativo + infradetectable (no descarta efecto real)
nodal	closeness	-0.028	0.028	0.947	FALSE	9 757	No significativo + infradetectable (no descarta efecto real)

Las siete métricas con $|d_z|$ entre 0.97 y 1.26 requieren entre 8 y 11 sujetos pareados para alcanzar el 80 % de potencia — un objetivo razonable para un estudio sucesor, y un orden de magnitud que conecta de forma natural con la $N = 15$ del dataset LSD (ds003059) que cerrará la INT-pipeline cuando llegue. Las cinco métricas con $|d_z|$ entre 0.62 y 0.89 (global_efficiency, density, small_worldness, modularity y closeness con su efecto nulo) requieren entre 12 y muchos más sujetos: closeness, con $d_z = -0.028$, pide 9 757 sujetos para detectar formalmente un efecto que en cualquier escala sustantiva es indistinguible de cero. Y degree_entropy, con $d_z = +0.199$, pide 201 sujetos: el «nulo bien establecido» que R3 y R9 ya identificaron se traduce aquí en un n requerido que confirma que el efecto, si existe, es minúsculo en la escala de Cohen [3].

La lectura combinada con R3 es clara y se sostiene sin retórica. El pool 13 produce un patrón direccional coherente con la hipótesis entrópica (ver R3 y R4 para la lectura sustantiva: integración global ↑, modularidad/path length ↓, eigenvector ↑, betweenness/participation ↓, degree_entropy plano), pero **siete u ocho de las trece métricas tienen un efecto que el diseño no puede confirmar con 80 % de potencia**. Que ninguna sobreviva FDR-BH sobre 13 con p_{FDR} mínima compartida a 0.117 no es entonces *evidencia contra* el efecto: es evidencia de que el diseño es estructuralmente sub-óptimo para *confirmar* efectos de tamaño cercano a $d_z \approx 1$, y eso vive en el casillero «no significativo + infradetectable (no descarta efecto real)» que la clasificación de 7.1 introduce explícitamente — alineada con el llamado de Button et al. (2013, *Nat Rev Neurosci* 14:365) sobre el riesgo de leer no-significancia como ausencia de efecto en estudios infrapotenciados.

Permutación pareada exacta confirma el paramétrico en signo y orden de magnitud en las 13 métricas

7.2 cierra el chequeo no paramétrico del pool 13 con un test de permutación pareado en su variante más limpia para diseños within-subject: el sign-flip exacto. La idea es directa — bajo H_0 el signo de la diferencia $\Delta_i = \text{PSIL}_i - \text{MTP}_i$ es intercambiable, por lo que enumerar las 2^N asignaciones de signos posibles construye el nulo exacto sin ningún supuesto distribucional [5]. Con $N = 6$ el espacio entero son $2^6 = 64$ outcomes, que el chunk enumera por completo en milisegundos. El p-valor sigue la corrección de Phipson & Smyth (2010, *Stat Appl Genet Mol Biol* 9:39), $p_{perm} = (b + 1)/(n_{eff} + 1)$, que evita los p-valores cero artificiales del re-muestreo MC; con $N = 6$ el piso combinatorio de esa fórmula es $1/65 \approx 0.0154$, lo que define la




Figure 1: Curva de sensibilidad (potencia vs d_z) para el diseño pareado N = 6, $\alpha = 0.05$ bilateral; $d_{\min,80} = 1.41$




Figure 2: Dotplot facetado por plano (global / nodal / advanced) con $\|d_z\|$ observado vs umbral $d_{\min,80} = 1.41$; verde = detectable, rojo = infradetectable




Figure 3: Scatter $-\log_{10}(p_{FDR} \text{ paramétrico})$ vs $-\log_{10}(p_{FDR} \text{ permutación})$ del pool 6.1.1 (13 métricas); diagonal = acuerdo perfecto, agreement como color, plano como forma

resolución mínima del test (cualquier $p_{perm} \approx 0.143$ que se ve repetidamente en la tabla corresponde a 9/63, el ranking observado más frecuente del pool en el contraste).

El criterio de éxito de 7.2 es la **concordancia direccional** con 6.1, descompuesta explícitamente en dos componentes alineados con la prosa del callout (cierre r2 H3-A): `sign_match` exige que el signo de la diferencia media observada por permutación coincida con el signo del d_z paramétrico, y `p_order_match` exige que p_{FDR}^{param} y p_{FDR}^{perm} caigan en el mismo orden de magnitud ($|\Delta \log_{10}| < 1$). `agreement` = "acuerdo" requiere ambas. El resultado es 13/13:

Métrica	Plano	d_z	p_{FDR}^{param}	p_{FDR}^{perm}	sign_match	p_order_match	agreement
mean_strength	global	+0.971	0.117	0.143	TRUE	TRUE	acuerdo
char_path_length	global	-1.035	0.117	0.143	TRUE	TRUE	acuerdo
assortativity	global	-1.058	0.117	0.143	TRUE	TRUE	acuerdo
clustering	global	+0.972	0.117	0.156	TRUE	TRUE	acuerdo
global_efficiency	global	+0.890	0.132	0.143	TRUE	TRUE	acuerdo
density	global	+0.783	0.164	0.156	TRUE	TRUE	acuerdo
small_worldness	global	+0.662	0.215	0.260	TRUE	TRUE	acuerdo
modularity	global	-0.623	0.222	0.273	TRUE	TRUE	acuerdo
eigenvector	nodal	+1.261	0.117	0.143	TRUE	TRUE	acuerdo
betweenness	nodal	-1.065	0.117	0.143	TRUE	TRUE	acuerdo
participation	nodal	-1.111	0.117	0.143	TRUE	TRUE	acuerdo
closeness	nodal	-0.028	0.947	0.969	TRUE	TRUE	acuerdo
degree_entropy	advanced	+0.199	0.701	0.717	TRUE	TRUE	acuerdo

La lectura es directa. Las trece métricas del pool 13 producen exactamente la misma dirección de contraste cuando se evalúan con el sign-flip exacto que cuando se evalúan con el t pareado paramétrico, y los p_{FDR} caen en el mismo orden de magnitud — ninguna salta de «sub-umbral nominal» a «manifiestamente cero» ni viceversa. La firma direccional del cerebro entrópico que R3 estableció no depende del supuesto de normalidad de las diferencias que el t paramétrico hace. Esto es lo más que puede pedirse a un chequeo de robustez no paramétrico con $N = 6$: ninguno de los 13 p_{FDR}^{perm} cruza 0.05, pero esa no era la pregunta — el techo combinatorio $1/65 \approx 0.0154$ aplicado a 13 tests BH-FDR no permite que ningún superviviente exista salvo si dos o más métricas comparten el rango pareado extremo simultáneamente, y en este dataset ninguno lo hace.

Conviene anotar una sutileza que el callout del chunk introduce (cierre r2 N1): las dos familias BH-FDR de 6.1 y 7.2 tienen el mismo tamaño (13 tests) y los mismos miembros, pero usan métodos distintos (paramétrico vs permutacional). Son por tanto dos p_{FDR} paralelas dentro de familias coextensivas, no una corrección anidada. La triangulación que 7.2 declara es la de los dos métodos sobre la misma familia, no la de dos correcciones sobre la misma familia.

Los QQ-plots no muestran desviaciones marcadas y Shapiro-Wilk no rechaza normalidad en ninguna métrica

7.3 hace dos cosas y *no* hace una tercera. Las dos que hace son: (1) renderizar los QQ-plots de las trece diferencias pareadas Δ_i para que la inspección visual sea posible — el ojo es mejor que cualquier p con $N = 6$ para detectar outliers o asimetrías marcadas— y (2) heredar `shapiro_p` de `STATS_13_1` y anotarlo con una nota textual de régimen. La que *no* hace, deliberadamente, es recalcar Shapiro-Wilk: el cierre r2 H6-B elimina el duplicado para evitar que el lector lea «7.3 confirma normalidad» como un test independiente cuando en realidad es el mismo test corrido sobre los mismos datos en 6.1. La columna `note` de `QQ_diagnostico.csv` deja explícito el régimen: «No evidencia contra normalidad (baja potencia con N pequeño, Razali 2011)» para las 13 métricas, todas con $p > 0.05$ — pero Razali y Wah [7] muestran que Shapiro-Wilk tiene baja potencia (~30 % con $N=10$ para desviaciones moderadas), así que no rechazar normalidad con $N = 6$ no la *garantiza*, sólo deja la inspección visual como única vía cualitativa disponible.

Métrica	Plano	$shapiro_p$	normal
assortativity	global	0.212	TRUE
char_path_length	global	0.952	TRUE
clustering	global	0.779	TRUE
density	global	0.491	TRUE
global_efficiency	global	0.369	TRUE
mean_strength	global	0.335	TRUE

Métrica	Plano	<i>shapiro_p</i>	normal
modularity	global	0.415	TRUE
small_worldness	global	0.840	TRUE
betweenness	nodal	0.674	TRUE
closeness	nodal	0.634	TRUE
eigenvector	nodal	0.531	TRUE
participation	nodal	0.494	TRUE
degree_entropy	advanced	0.262	TRUE

El Shapiro mínimo del pool es $p = 0.212$ (assortativity), bien por encima del 0.05 nominal; los QQ-plots no muestran desviaciones marcadas en ninguno de los trece paneles —los puntos caen sobre la diagonal teórica con la dispersión esperable de $N = 6$ —; y el patrón de acuerdo t /Wilcoxon que R3 ya documentó (las cuatro métricas con discordancia t/W son atribuibles al techo combinatorio del Wilcoxon, no a violación de supuestos) es coherente con un régimen en el que los datos no muestran señal de no-normalidad detectable. La práctica de 6.1 —reportar siempre t y Wilcoxon en paralelo, sin usar Shapiro como gatekeeper— es exactamente la que Lumley et al. [8] y Rochon et al. [9] recomiendan: el two-stage testing (elegir entre paramétrico y no paramétrico según el resultado de Shapiro) infla el error de Tipo I del procedimiento combinado y no resuelve la cuestión sustantiva. 7.3 deja Shapiro como diagnóstico y los QQ-plots como inspección visual; la decisión confirmatoria queda en la triangulación de 6.1 + 7.2 (paramétrico + permutación), no en el resultado de Shapiro.

Bootstrap BCa 95 %: ocho de las trece métricas con IC que excluye el cero, todas en el bloque de $|d_z| \geq 0.97$

7.4 cierra el cuarto eje de robustez con un bootstrap pareado del IC 95 % de d_z y d_{av} . La técnica es la canónica para tamaños de efecto pareados con N pequeño y distribuciones potencialmente asimétricas (Efron 1979, *Ann Stat* 7:1; Efron [10]; Kelley [11]): $R = 10\,000$ re-muestreos con reposición de los seis pares $(g_1^{(i)}, g_2^{(i)})$ a partir de los cuales se calculan $d_z^{(b)}$ y $d_{av}^{(b)}$ por réplica, e IC 95 % BCa (bias-corrected and accelerated) sobre la distribución bootstrap. El cierre r2 introdujo dos mejoras notables sobre la implementación anterior: el bootstrap toma los pares completos (no las diferencias precomputadas), lo que permite estimar IC para d_z y d_{av} en la misma muestra conjunta vía `boot.ci(index = 1, 2)`; y $R = 10\,000$ sustituye al previo $R = 5\,000$, convención BCa estándar a coste computacional negligible.

Métrica	Plano	d_z	IC 95 % BCa d_z	Excluye 0	d_{av}	IC 95 % BCa d_{av}	Excluye 0	ci_method
eigenvector	nodal	+1.261	[+0.403, +3.463]	sí	+1.839	[+0.410, +3.104]	sí	BCa
participation	nodal	-1.111	[-2.173, -0.604]	sí	-0.383	[-0.967, -0.079]	sí	BCa
betweenness	nodal	-1.065	[-1.831, -0.030]	sí	-1.361	[-2.028, -0.341]	sí	BCa
assortativity	global	-1.058	[-2.528, +0.108]	no	-1.376	[-2.516, +0.191]	no	BCa
char_path_length	global	-1.035	[-2.357, -0.034]	sí	-1.565	[-3.197, -0.324]	sí	BCa
clustering	global	+0.972	[+0.100, +2.892]	sí	+0.991	[-0.104, +3.814]	no	BCa
mean_strength	global	+0.971	[-0.087, +1.956]	no	+1.518	[-0.182, +2.619]	no	BCa
global_efficiency	global	+0.890	[-0.177, +1.572]	no	+1.405	[-0.200, +2.474]	no	BCa
density	global	+0.783	[-0.110, +1.630]	no	+1.355	[-0.438, +2.849]	no	BCa
small_worldness	global	+0.662	[-0.380, +1.785]	no	+1.152	[-0.401, +2.771]	no	BCa
modularity	global	-0.623	[-1.502, +0.351]	no	-0.449	[-1.181, +0.162]	no	BCa
degree_entropy	advanced	+0.199	[-0.769, +1.239]	no	+0.279	[-1.051, +1.720]	no	BCa
closeness	nodal	-0.028	[-1.098, +0.956]	no	-0.044	[-1.549, +1.793]	no	BCa

Cinco métricas tienen el IC 95 % de d_z que excluye el cero (eigenvector, participation, betweenness, char_path_length y clustering), y la sexta —mean_strength— se queda casi pegada al borde con IC inferior -0.087. Esto suma seis de las trece y compone exactamente el conjunto que R3 reportó en cabeza de la firma direccional: dos centralidades transmodales (eigenvector ↑, betweenness ↓), un descriptor de papel inter-modular (participation ↓), la integración global como long-range (char_path_length ↓), la segregación funcional (clustering ↑) y la fuerza media (mean_strength ↑ al borde). Las siete restantes tienen IC que abrazan el cero, lo que es coherente con sus $|d_z|$ por debajo de 0.89.

Una sutileza no menor del cuadro: en participation el IC 95 % BCa de d_z es [-2.17, -0.60] —que excluye el cero— pero el IC de d_{av} es [-0.97, -0.08], también excluyente pero apenas. Esto refleja la divergencia conocida entre las dos definiciones de Cohen para diseños pareados (cf. Lakens 2013; Borenstein 2009): d_z divide por $sd(\Delta)$ y captura la consistencia direccional




Figure 4: Grid 4×4 de QQ-plots de las diferencias pareadas $\Delta_i = \text{PSIL}_i - \text{MTP}_i$ por métrica del pool 6.1.1; el panel inferior derecho queda vacío al sobrar uno con 13 métricas




Figure 5: Forest plot del pool 6.1.1: d_z y d_{av} por métrica con IC 95 % BCa, R = 10 000 réplicas, color por plano

dentro de sujeto; d_{av} divide por la media de los dos sd condicionales y se acerca a una métrica de tamaño «poblacional» comparable entre estudios. Para participation, $d_z = -1.111$ refleja que las seis diferencias pareadas van en la misma dirección con poca dispersión relativa; $d_{av} = -0.383$ refleja que el desplazamiento medio es pequeño relativo a la varianza condicional bruta. Las dos cifras son válidas como descriptores; R10 las reporta en paralelo siguiendo el cierre 6.1 r2.

La nota técnica que toca dejar explícita es que **el método aplicado es BCa puro en las 13 métricas** —ninguna fila tiene `ci_method = "percentile (BCa fallback)"`, el fallback diseñado para casos donde el bootstrap colapsa— y todos los IC son percentil 2.5–97.5 sobre las 10 000 réplicas BCa-correctas. Sin embargo, la caveat de Davison y Hinkley (1997, *Bootstrap Methods*, Ch. 5) sigue siendo válida: con $N = 6$ la distribución empírica de partida sólo contiene seis pares únicos, y las réplicas son combinatorias finitas que infrarepresentan la verdadera distribución sub-yacente. La cobertura nominal 95 % es por tanto aproximada: un IC bootstrap que excluye 0 con $N = 6$ debe replicarse en muestras mayores antes de declararse robusto, no es una inferencia confirmatoria en el sentido fuerte. Es un descriptor del rango plausible del efecto. Esa es exactamente la lectura que R10 hace de las seis (o cinco si se descuenta `mean_strength` al borde) métricas con IC excluyente: convergencia indirecta con la convergencia inter-pipeline de R4, no un sustituto del FDR.

Lectura integrada de los cuatro ejes

Los cuatro chequeos de 7 convergen sobre el mismo cuadro que R3 dejó establecido y al que R4–R9 fueron añadiendo capas. La firma direccional del cerebro entrópico —integración global $\uparrow$ (`mean_strength`, `global_efficiency`, `density`, `small_worldness`, `clustering` $\uparrow$; `char_path_length`, `modularity`, `assortativity` $\downarrow$), centralidades transmodales reorganizadas (`eigenvector` $\uparrow$; `betweenness`, `participation` $\downarrow$), `degree_entropy` plano— se sostiene en signo en las trece métricas (R3, t y Wilcoxon paralelos), se sostiene en signo bajo permutación pareada exacta de las trece (R10/7.2, `sign_match` 13/13), produce IC bootstrap que excluyen el cero en cinco más una al borde (R10/7.4, `eigenvector`, `participation`, `betweenness`, `char_path_length`, `clustering` y `mean_strength` al borde), y se mantiene como propiedad del contraste —no del pipeline— en la mayoría bajo cambio de denoising (R4, 11/13 convergentes bajo S0). Lo que el diseño no puede dar en este dataset es la significación FDR-BH formal sobre el pool 13, y 7.1 lo explica directamente: el N pareado limita a $d_z \geq 1.41$ el umbral detectable al 80 %, y siete u ocho de los trece efectos observados se quedan justo por debajo de esa cota, sin que ello signifique que sean ceros sustantivos. La línea de continuidad con la INT-pipeline ya tiene marcada su pieza por hacer — replicar este mismo bloque sobre $N = 15$ (ds003059) cuando LSDPrep cierre, donde $d_{\min,80}$ baja a ≈ 1.0 y el techo combinatorio del permutacional baja a $\approx 3 \times 10^{-5}$.

Limitaciones y caveats

R10 hereda los caveats estructurales que cierran R3 y R5 ($N = 6$ PFM pareados; ausencia de FDR sobre 26 796 aristas; regla S0 + criterios de credibilidad) y añade tres propios al plano de robustez.

El primero es la consecuencia directa de la curva de sensibilidad de 7.1. La afirmación «el diseño puede detectar al 80 % de potencia efectos $|d_z| \geq 1.41$ » es una propiedad estructural del crossover $N = 6 + \alpha = 0.05 + t$ pareado, no una estimación dependiente de los datos — Hoenig y Heisey [1] y Lenth [2] son inequívocos en distinguirla de la potencia post-hoc, que sería la fallacy. Pero la implicación práctica es la misma: ninguna métrica del pool 13 caería en el casillero «detectable y detectada» aunque el p_{FDR} cruzara 0.05, porque ninguna tiene $|d_z| \geq 1.41$. La interpretación correcta de los doce «no significativo + infradetectable» es la que el chunk fija: «no descarta efecto real» (Button et al. [4], *Nat Rev Neurosci* 14:365) — el patrón direccional consistente con la hipótesis entrópica no puede tomarse como confirmado por R10, sólo como compatible con ella bajo un diseño que no puede confirmarlo.

El segundo se refiere al espacio de permutación finito de 7.2. Con $N = 6$ el sign-flip exacto enumera $2^6 = 64$ outcomes, lo que fija el p_{perm} mínimo en $1/65 \approx 0.0154$ tras la corrección Phipson–Smyth — y eso, aplicado a 13 tests BH-FDR, deja al FDR mínimo alcanzable bastante por encima de 0.05 salvo coincidencia simultánea en el rango extremo. La concordancia 13/13 paramétrico–permutación que R10 reporta no es por tanto evidencia de un test no paramétrico potente; es evidencia de que la *forma* del contraste (signo + orden de magnitud) no depende del supuesto distribucional del t . Las dos cosas son distintas y conviene no confundirlas: el test de permutación es robusto pero está techado por la combinatoria.

El tercero se refiere al bootstrap BCa de 7.4. La caveat de Davison y Hinkley (1997, *Bootstrap Methods*, Ch. 5) está explícitamente recogida en el callout-warning del chunk y se mantiene aquí: con $N = 6$ la cobertura del IC 95 % es aproximada, las réplicas son combinatorias finitas que infrarepresentan la verdadera distribución, y un IC que excluye 0 con $N = 6$ debe replicarse en muestras mayores antes de declararse robusto. Las seis métricas con IC 95 % BCa que excluyen el cero (cinco al borde duro y `mean_strength` al borde blando) son descriptores del rango plausible, no inferencia confirmatoria. La pieza de credibilidad que sí cierra el círculo es R4 — la convergencia 10/13 con `n_dir_noGSR` = 6/6 que esa convergencia inter-pipeline reporta es una evidencia inter-método que el IC bootstrap no puede dar por sí solo.

Finalmente, las cuatro sub-secciones de 7 operan sobre el pool 13 (las 8 globales + 4 nodales no redundantes + degree_entropy) y no sobre el plano POS/NEG por red (R5), el inter-red 8×8 (R6), el seed-based subcortical (R7), el acoplamiento MEQ/EBI (R8) ni los dos bloques de entropía dinámica (R9). El 7 está diseñado como cierre estadístico del bloque topológico del contraste; cada uno de los otros bloques tiene su propio chequeo de robustez interno (LOO en R5, sign test + BF + REBUS en R6, top-ROI + heatmap por red en R7, bootstrap percentil + p_perm en R8, sweep N_{bins} + sweep densidad en R9). Lo que R10 *no* hace es agregar los efectos del bloque POS por red al pool del sensitivity analysis ni computar IC bootstrap para los 28 pares inter-red — esas piezas viven en sus informes respectivos y el diseño S0 las trata como bloques independientes, no como una única familia confirmatoria.

Bibliografía

1. Hoenig, J. M., & Heisey, D. M. (2001). The abuse of power: The pervasive fallacy of power calculations for data analysis. *The American Statistician*, 55(1), 19–24.
2. Lenth, R. V. (2007). Post hoc power: Tables and commentary. *The American Statistician*, 61(1), 38–42.
3. Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2.^a ed.). Lawrence Erlbaum.
4. Button, K. S., Ioannidis, J. P. A., Mokrysz, C., Nosek, B. A., Flint, J., Robinson, E. S. J., & Munafò, M. R. (2013). Power failure: Why small sample size undermines the reliability of neuroscience. *Nature Reviews Neuroscience*, 14(5), 365–376.
5. Edgington, E. S., & Onghena, P. (2007). *Randomization Tests* (4^a ed.). Chapman & Hall/CRC.
6. Phipson, B., & Smyth, G. K. (2010). Permutation P-values should never be zero. *Stat Appl Genet Mol Biol*, 9(1), Art. 39.
7. Razali, N. M., & Wah, Y. B. (2011). Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *J Stat Model Anal*, 2(1), 21–33.
8. Lumley, T., Diehr, P., Emerson, S., & Chen, L. (2002). The importance of the normality assumption in large public health data sets. *Annual Review of Public Health*, 23, 151–169.
9. Rochon, J., Gondan, M., & Kieser, M. (2012). To test or not to test: Preliminary assessment of normality when comparing two independent samples. *BMC Med Res Methodol*, 12, 81.
10. Efron, B. (1987). Better bootstrap confidence intervals. *JASA*, 82(397), 171–185.
11. Kelley, K. (2007). Confidence intervals for standardized effect sizes: Theory, application, and implementation. *Educ Psychol Meas*, 67(5), 738–757.
12. Lakens, D. (2013). Calculating and reporting effect sizes. *Front Psychol*, 4, 863.
13. Borenstein, M., Hedges, L. V., Higgins, J. P. T., & Rothstein, H. R. (2009). *Introduction to Meta-Analysis*. John Wiley & Sons.
14. Davison, A. C., & Hinkley, D. V. (1997). *Bootstrap Methods and Their Application*. Cambridge University Press (Ch. 5).